

AgroSentimento News

Newsletter diária de inteligência de mercado para o agronegócio,
curada por NLP no formato editorial “The News”

DOCUMENTO DE REQUISITOS DE PRODUTO (PRD)

Squad 3 — Processamento de Linguagem Natural (NLP)

Disciplina: Aprendizado de Máquina II

Tema institucional: Mineração de sentimentos de boletins e informativos de grãos

Versão 1.0 · 10 de setembro de 2026

Fontes utilizadas na elaboração deste PRD:

- Board de planejamento do squad (Trello — “Kanban”, export JSON)
- Site institucional da newsletter The News (thenewsc.com.br)
- Model card do BERTimbau ([neuralmind/bert-base-portuguese-cased](https://neuralmind.com.br/bert-base-portuguese-cased), Hugging Face)
- ENCONTRO 04 — 28/08/26 (diretrizes da atividade acadêmica, Squad 3)

Sumário

1. Visão Geral e Contexto Acadêmico
2. Problema e Oportunidade
3. Objetivos do Produto
4. Personas
5. Referências de Produto (Benchmark)
6. Escopo Funcional — User Stories
7. Arquitetura da Solução e Pipeline de Dados
8. Especificação por Componente Técnico
9. Stack Tecnológica
10. Plano de Sprints e Responsabilidades (Squad 3)
11. Métricas de Sucesso e Critérios de Aceite
12. Riscos e Mitigações
13. Fora de Escopo (Sprint 1–4)

1. Visão Geral e Contexto Acadêmico

Este documento formaliza os requisitos de produto do projeto conduzido pelo **Squad 3** na disciplina de Aprendizado de Máquina II, cujo tema institucional atribuído é **Processamento de Linguagem Natural (NLP) aplicado à mineração de sentimentos de boletins e informativos de grãos**, conforme as diretrizes do Encontro 04 (28/08/2026). A entrega está organizada em quatro sprints, com Sprint Review inicial em 04/09/2026.

O produto concebido pelo squad — **AgroSentimento News** — é uma newsletter diária automatizada que replica a proposta editorial da newsletter brasileira **The News** (formato de leitura rápida, linguagem leve e curadoria objetiva das principais notícias do dia), aplicada verticalmente ao agronegócio. O sistema raspa continuamente os principais portais do setor, agrupa semanticamente notícias que tratam do mesmo fato, calcula um índice de relevância inspirado na lógica do Google Trends, classifica o sentimento de mercado de cada cobertura em um “termômetro setorial”, gera previsões de curto prazo em formato de mercado preditivo (estilo Polymarket) e entrega, todos os dias antes das 5h30, uma edição de 5 matérias pronta para aprovação humana e disparo por e-mail.

Este PRD consolida e formaliza o planejamento já em curso no board de gestão do squad (Trello “Kanban”) e no site de referência editorial (The News), traduzindo as 16 histórias de usuário já levantadas, os cards técnicos distribuídos entre as três duplas do squad e os critérios de aceite definidos, em um documento único de especificação de produto.

Nota metodológica: o board do Trello foi utilizado como fonte primária de escopo funcional e técnico (histórias de usuário, tarefas e critérios de aceite já redigidos pela equipe); o site thenewsgcc.com.br foi utilizado como referência de tom editorial e formato de entrega; e o model card do BERTimbau foi utilizado para validar a escolha de modelos de linguagem em português na camada de NLP (seção 9).

2. Problema e Oportunidade

Profissionais e investidores do agronegócio precisam acompanhar diariamente múltiplos portais especializados para se manterem informados sobre o setor. Esse processo é fragmentado, redundante (o mesmo fato é coberto por vários veículos com redações distintas) e tecnicamente denso — boletins de mercado tendem a ser longos, formais e pouco escaneáveis. Não existe hoje uma síntese diária que (a) consolide as coberturas de múltiplos portais em fatos únicos, (b) hierarquize o que realmente teve repercussão de mercado, (c) traduza o impacto de cada notícia em um sinal objetivo de “bom ou ruim para o produtor”, e (d) entregue tudo isso em um formato de leitura de poucos minutos.

Isso é evidenciado diretamente pelas histórias de usuário levantadas pelo squad, entre elas:

- **US-1** — necessidade de consolidar 5 portais em um único ponto de leitura;
- **US-2 / US-4** — eliminar duplicidade e fragmentação de cobertura do mesmo fato;
- **US-5 / US-10** — separar o que teve repercussão real de mercado de matérias de assessoria/institucionais;
- **US-6** — traduzir a notícia em um sinal rápido de impacto financeiro para o produtor.

3. Objetivos do Produto

Objetivo	Descrição
O1 — Consolidação	Unificar a cobertura diária de 5 portais de agronegócio em uma única fonte de leitura.
O2 — Deduplicação semântica	Agrupar automaticamente notícias que descrevem o mesmo fato, mesmo com redações diferentes, via embeddings vetoriais.

O3 — Priorização por relevância	Ranquear os fatos do dia por um score de relevância inspirado no Google Trends, ponderando diversidade de fontes e menção a entidades críticas do setor.
O4 — Sinalização de sentimento	Classificar cada cobertura em um termômetro setorial (positivo / negativo / neutro) com intensidade percentual e justificativa curta.
O5 — Projeção de curto prazo	Gerar cenários preditivos binários (estilo Polymarket) com data de resolução objetiva para os fatos de maior impacto.
O6 — Autonomia com curadoria humana	Executar toda a análise de forma autônoma durante a madrugada, mantendo um painel de aprovação humana antes do disparo.
O7 — Entrega editorial no formato The News	Publicar em e-mail responsivo, com linguagem leve e estrutura de blocos curtos, reproduzindo o padrão de legibilidade da newsletter de referência.

4. Personas

Persona	Perfil e necessidade	US relacionadas
Assinante do agronegócio	Quer acompanhar o setor sem abrir múltiplos portais nem ler cobertura repetida; valora leitura rápida e visual no celular.	US-1, US-2, US-4, US-11, US-14
Produtor / investidor rural	Precisa saber rapidamente se uma notícia é boa ou ruim para o seu faturamento, e quer projeções de curto prazo com probabilidades.	US-6, US-9, US-10
Curador(a) da newsletter	Precisa de uma tela de revisão rápida (menos de 5 min) para aprovar a edição do dia, com alertas de falha de coleta e trabalho pesado já pronto ao acordar.	US-7, US-8, US-12, US-13, US-15
Equipe da plataforma (squad)	Precisa validar que o sistema é robusto sob volume e cenários de crise de mercado antes de confiar na automação total.	US-16

5. Referências de Produto (Benchmark)

5.1 The News (thenewsc.com.br)

Newsletter diária brasileira, enviada gratuitamente por e-mail, que sintetiza os principais acontecimentos do dia em blocos curtos, com linguagem leve, títulos com trocadilho e foco em leitura completa em poucos minutos. Em fevereiro de 2025 a publicação lançou o **Termômetro de Imparcialidade**, uma enquete diária que pede ao leitor para avaliar o viés da edição — referência direta adotada pelo squad para o conceito de “termômetro setorial” usado neste produto (ver US-6 e componente de classificação de sentimento, seção 8.3).

Elementos de formato replicados no AgroSentimento News:

- Estrutura fixa em blocos curtos por matéria (título com trocadilho, contexto, por que importa, número em destaque);
- Tom de voz leve, com sarcasmo equilibrado e analogias simples para termos técnicos (checklist “Engenharia da Persona”, seção 8.7);
- Limite de leitura de até 180 palavras por notícia (leitura inferior a 1 minuto);
- Envio matinal, com curadoria humana revisando o conteúdo antes do disparo;
- Elemento visual de “termômetro” como marca de produto, adaptado aqui para sentimento de mercado em vez de viés editorial.

5.2 BERTimbau (neuralmind/bert-base-portuguese-cased)

Modelo BERT pré-treinado para português brasileiro (arquitetura BERT-Base, 12 camadas, 110M de parâmetros, licença MIT), desenvolvido pela Neuralmind e disponibilizado na Hugging Face. O model card reporta desempenho estado-da-arte em três tarefas de downstream NLP em português: reconhecimento de entidades nomeadas (NER), similaridade textual e inferência textual — as três capacidades centrais que o pipeline deste produto precisa (deduplicação semântica, extração de entidades críticas e classificação de sentimento).

Uso previsto no produto: o BERTimbau (ou um classificador especializado derivado dele) é a referência de modelo base em português para a tarefa de classificação de sentimento setorial (seção 8.3). Para a etapa de deduplicação semântica por similaridade de vetores (seção 8.1), o squad optou tecnicamente por um modelo multilíngue de sentence-embeddings (paraphrase-multilingual-MiniLM-L12-v2, via biblioteca sentence-transformers) por ser otimizado nativamente para similaridade de frases e mais leve em tempo de inferência — o BERTimbau permanece como opção de comparação/fallback nessa etapa e como base

preferencial sempre que a tarefa exigir compreensão fina de português (sentimento, NER).

6. Escopo Funcional — User Stories

As 16 histórias de usuário abaixo foram levantadas e priorizadas pelo squad no Product Backlog do board Kanban e constituem o escopo funcional completo do produto ao longo das quatro sprints.

US-1 — Chegar de abrir 5 abas todo dia para saber o que rolou no agro

Como assinante do agronegócio, quero que a plataforma monitore os 5 principais portais do setor para que eu não precise acessar múltiplos sites todos os dias para saber o que está acontecendo no mercado.

US-2 — Evitar que a mesma notícia apareça duas vezes com palavras diferentes

Como assinante, quero que a plataforma entenda o significado semântico das notícias para que matérias com palavras diferentes, mas que relatam o mesmo acontecimento, sejam identificadas como uma única cobertura.

US-3 — Trocar relatórios técnicos maçantes por uma leitura rápida e divertida matinal

Como leitor da newsletter, quero ler os acontecimentos do campo em uma linguagem ágil, descomplicada e com humor inteligente, para me atualizar com prazer pela manhã em vez de ler relatórios técnicos sonolentos.

US-4 — Juntar desdobramentos de vários sites em uma única história completa

Como assinante, quero que as matérias sobre o mesmo fato sejam agrupadas em uma cobertura única para que eu não receba múltiplos tópicos tratando do mesmo acontecimento sob ângulos repetitivos.

US-5 — Descobrir o que realmente agitou o mercado e ignorar matérias de assessoria

Como assinante, quero receber no meu boletim apenas os acontecimentos de maior repercussão na mídia, para ter certeza de que estou informado sobre os assuntos mais discutidos no setor.

US-6 — Bater o olho e saber na hora se a notícia é boa ou ruim para o bolso do produtor

Como produtor ou investidor rural, quero ver rapidamente se uma notícia é positiva, negativa ou neutra para o agronegócio, para identificar em segundos se o cenário beneficia ou prejudica meu faturamento.

US-7 — Garantir que as notícias quentes da noite não fiquem de fora do café da manhã

Como curador da newsletter, quero que as notícias sejam raspadas continuamente sem intervenção manual para que todo o material do dia esteja consolidado para a edição da madrugada.

US-8 — Receber os rascunhos da IA já formatados e sem erros visuais para agilizar o trabalho

Como curador, quero que o modelo de linguagem entregue a redação da notícia junto com os dados do termômetro em JSON rigoroso para evitar quebras no sistema.

US-9 — Prever o que vai acontecer nos próximos dias com porcentagens claras de mercado

Como leitor da newsletter, quero ver projeções de desdobramentos dos próximos dias com probabilidades percentuais (estilo Polymarket), para entender as chances reais de eventos de mercado acontecerem no curto prazo.

US-10 — Priorizar decisões de crédito, cotações e governo antes de notícias institucionais

Como leitor investidor, quero que decisões de crédito, geopolítica e cotações de commodities recebam prioridade na curadoria para que matérias com potencial financeiro fiquem no topo da edição.

US-11 — Garantir um boletim equilibrado que não fale só de soja a edição inteira

Como leitor, quero uma edição com assuntos variados para não receber um boletim composto exclusivamente por um único assunto (ex.: 5 notícias sobre a mesma cultura agrícola).

US-12 — Dar o sinal verde no disparo do dia em menos de 5 minutos sem dor de cabeça

Como curador da newsletter, quero uma tela intuitiva para revisar os 5 textos, checar as odds do Polymarket e aprovar o disparo em poucos minutos para manter a edição sob controle humano.

US-13 — Saber na hora se algum portal saiu do ar antes que o boletim saia incompleto

Como curador do produto, quero ser notificado imediatamente se um dos 5 portais parar de responder para não rodar a seleção diária com base de dados defasada.

US-14 — Abrir o e-mail no celular e ver gráficos limpos do termômetro e das odds

Como assinante, quero abrir meu e-mail e ver gráficos visuais limpos do termômetro de mercado e das probabilidades do Polymarket, para que a leitura seja moderna, visual e intuitiva no celular.

US-15 — Acordar com o trabalho pesado de seleção e redação pronto antes das 5h30

Como curador da newsletter, quero que todo o fluxo analítico execute de forma automática durante a madrugada para que a edição matinal esteja 100% pronta para aprovação quando eu acordar.

US-16 — Colocar o robô à prova em dias de crise para garantir que ele não erre na prática

Como equipe da plataforma, queremos submeter o sistema a um grande volume de notícias passadas para garantir que o algoritmo não trave sob pressão e que as previsões façam sentido econômico.

7. Arquitetura da Solução e Pipeline de Dados

O sistema opera como um pipeline diário orquestrado, executado de forma autônoma durante a madrugada e encerrado com um ponto de controle humano antes da publicação. As etapas abaixo refletem o fluxo consolidado a partir dos cards técnicos do board (“Pipeline Diário Integrado de Execução Autônoma”).

- **1. Coleta (scraping contínuo)** — scrapers dedicados para os 5 portais-fonte, agendados a cada 3 horas, com deduplicação por URL.
- **2. Normalização e persistência** — limpeza de HTML/anúncios/rodapés e gravação em banco relacional (PostgreSQL) com restrição de unicidade por URL.
- **3. Embeddings** — vetorização semântica de título + lead de cada matéria via sentence-transformers.
- **4. Clusterização** — agrupamento de matérias que tratam do mesmo fato via DBSCAN com distância de cosseno.
- **5. Score de relevância** — cálculo de um índice estilo Google Trends por cluster, ponderando diversidade de fontes e volume de menções, com bônus para entidades críticas do setor (NER).
- **6. Seleção editorial** — seleção gulosa (greedy) dos 5 clusters finais, limitando no máximo 2 por macro-tema (filtro anti-monotonia).
- **7. Geração de conteúdo via LLM** — redação da notícia no tom “The News Agro”, classificação de sentimento (termômetro) e geração do cenário preditivo (estilo Polymarket), tudo retornado em JSON estruturado e validado por schema.
- **8. Curadoria humana** — painel web onde o curador revisa, edita e aprova os 5 textos, o termômetro e as odds antes do disparo.
- **9. Disparo** — envio do e-mail responsivo via provedor transacional (Resend/SendGrid), com componentes visuais do termômetro e do card preditivo.
- **10. Monitoramento** — verificação de integridade dos scrapers com alerta automático em caso de portal fora do ar.

Meta operacional: pipeline ponta a ponta (coleta já concluída → e-mail pronto para aprovação) executado em menos de 8 minutos para um volume de até 200 matérias, com os 5 tópicos finais disponíveis no painel de curadoria antes das 05h15.

8. Especificação por Componente Técnico

Cada componente abaixo corresponde a um card técnico do board, já com as tarefas e critérios de aceite definidos pelo squad. A responsabilidade por dupla e sprint está indicada e detalhada também na seção 10.

8.1 Centralização Automatizada das Coberturas do Agro

Sprint 1

Dupla A

Fontes de coleta definidas pelo squad (lista “Sites” do board): TheAgriBiz, AgFeed, Agrolink, Canal Rural e Notícias Agrícolas.

Tarefas:

- Subir e configurar banco PostgreSQL via Docker/Cloud com migrações prontas;
- Criar a tabela `artigos` com campos: `id`, `portal_nome`, `url`, `titulo`, `lead`, `corpo_texto`, `publicado_em`, `processado_status`;
- Implementar scrapers automáticos para os 5 portais-fonte com `trafilatura` ou `newspaper3k`;
- Criar filtros regex para eliminar anúncios, rodapés e links institucionais (“leia mais”);
- Criar restrição de unicidade na coluna `url` para blindar o banco contra duplicações.

Critérios de aceite:

- ✓ Inserções de URLs já existentes são descartadas sem interromper a execução do fluxo;

- ✓ O banco contém pelo menos 10 matérias reais extraídas de cada um dos 5 portais;
- ✓ Nenhum elemento de código HTML, menu ou script inline permanece no campo corpo_texto.

8.2 Representação Vetorial para Comparação de Notícias

Sprint 1

Dupla B

Tarefas:

- Configurar ambiente de inferência com sentence-transformers e PyTorch;
- Carregar o modelo multilíngue paraphrase-multilingual-MiniLM-L12-v2;
- Implementar rotina de concatenação otimizada de título e lead do artigo;
- Criar função de lote que recebe textos e devolve a matriz de embeddings $N \times 384$.

Critérios de aceite:

- ✓ Processamento em lote de 200 matérias executado em menos de 45 segundos em CPU;
- ✓ Duas reportagens de portais concorrentes sobre o mesmo relatório de safra apresentam similaridade de cosseno superior a 0,80.

8.3 Engenharia da Persona “The News Agro”

Sprint 1

Dupla C

Tarefas:

- Desenvolver o system prompt definindo o tom de voz da newsletter: sarcasmo equilibrado, foco no impacto real para quem produz e analogias simples;
- Estabelecer a estrutura obrigatória em blocos: título com trocadilho, o que rolou, por que isso importa e o número em destaque;
- Montar few-shot examples contextualizados com temas agrícolas (fertilizantes, clima, boi gordo, soja);
- Conduzir testes cegos com 10 matérias reais para validação qualitativa do tom.

Critérios de aceite:

- ✓ 100% dos textos gerados na bateria de testes seguem rigorosamente a estrutura dos 4 blocos;
- ✓ Cada notícia é redigida em até 180 palavras (leitura de menos de 1 minuto);
- ✓ Todos os termos técnicos agrícolas complexos recebem explicações didáticas em linguagem natural.

8.4 Representação de Clusters e Agrupamento de Fatos

Sprint 2

Dupla B

Tarefas:

- Implementar o algoritmo DBSCAN do scikit-learn utilizando distância de cosseno;
- Calibrar o parâmetro de distância eps (intervalo entre 0,15 e 0,25) usando as notícias reais da Sprint 1;
- Configurar min_samples=1 para garantir que furos de reportagem de um único veículo formem clusters válidos;
- Vincular a cada artigo do banco o seu respectivo cluster_id.

Critérios de aceite:

- ✓ Reportagens de 3 portais distintos cobrindo o mesmo embargo comercial recebem o mesmo cluster_id;
- ✓ Menos de 5% de agrupamentos incorretos (matérias de assuntos diferentes postas no mesmo cluster).

8.5 Algoritmo de Relevância / Score Estilo Google Trends

Sprint 2

Dupla B

Este componente é a resposta técnica direta à ideia original do squad de usar um “score estilo Google Trends”: em vez de depender do volume de busca externo do Google Trends, o índice é calculado internamente a partir da diversidade e do volume de cobertura jornalística real — mais robusto e sem dependência de uma API de terceiros com cotas e latência.

Tarefas:

- Criar métrica de diversidade de fontes por cluster contando a quantidade de veículos únicos envolvidos (D);
- Implementar a fórmula de pontuação: $\text{Score} = (D \times 3.0) + (\text{Volume Total} \times 1.0)$;
- Identificar a notícia mais central do cluster (mais próxima do vetor centroide) para ser o texto-base da IA;
- Ordenar e ranquear todos os clusters gerados nas últimas 24 horas.

Critérios de aceite:

- ✓ Um tema publicado em 4 portais diferentes obtém obrigatoriamente score maior do que um tema publicado 5 vezes por um único portal;
- ✓ O algoritmo processa e devolve a lista ordenada dos clusters em menos de 5 segundos.

8.6 Classificador do Termômetro Setorial (Positivo / Negativo / Neutro)

Sprint 2

Dupla B

Tarefas:

- Definir a taxonomia do sentimento voltada às regras de negócio do agro (ex.: alta de insumos é negativa; chuva em período de seca é positiva);
- Estruturar prompt de few-shot com LLM ou classificador BERT especializado (BERTimbau) para extrair o sentimento e um percentual de intensidade (0 a 100%);
- Configurar o retorno com uma justificativa curta (1 frase) sobre o porquê daquele impacto;
- Testar a classificação com uma massa de 30 notícias históricas com viés conhecido.

Critérios de aceite:

- ✓ Taxa de acerto mínima de 85% na classificação do viés mercadológico em comparação com a avaliação de um especialista;
- ✓ O modelo devolve obrigatoriamente a classificação (POSITIVO, NEGATIVO ou NEUTRO), percentual de intensidade e justificativa.

8.7 Automação Agendada da Coleta de Matérias

Sprint 2

Dupla A

Tarefas:

- Configurar agendador de tarefas em background (APScheduler ou Celery) com disparos a cada 3 horas;

- Integrar verificação prévia no banco para não reprocessar links já existentes;
- Implementar sistema de log registrando horários de início e término, volume de matérias coletadas e exceções.

Critérios de aceite:

- ✓ O pipeline de coleta executa de maneira autônoma por 48 horas ininterruptas;
- ✓ O volume de notícias armazenadas cresce de forma condizente sem duplicação de URLs.

8.8 Geração Estruturada das Notícias e Termômetro via LLM

Sprint 2

Dupla C

Tarefas:

- Criar schemas de dados via Pydantic validando a estrutura do texto e dos dados de sentimento;
- Implementar a chamada na API de LLM com modo JSON forçado (`response_format={"type": "json_object"}`);
- Adicionar política de tentativas automáticas (tenacity) com até 3 tentativas contra instabilidades de rede.

Critérios de aceite:

- ✓ A resposta da LLM é validada pelo esquema Pydantic sem campos nulos ou formatação corrompida;
- ✓ Falhas temporárias de rede disparam novas tentativas transparentes sem abortar o script.

8.9 Motor de Geração de Cenários Preditivos (Estilo Polymarket)

Sprint 3

Dupla C

Tarefas:

- Adicionar ao pipeline da LLM a tarefa de formular uma pergunta objetiva de previsão de curto prazo ligada à notícia;
- Definir probabilidade complementar para dois cenários: Probabilidade SIM + Probabilidade NÃO = 100%;
- Exigir na instrução um gatilho de resolução objetivo e mensurável com prazo definido (ex.: “Até o fechamento da bolsa na sexta”, “Relatório Secex da próxima semana”);
- Integrar esses dados ao schema Pydantic geral da notícia.

Critérios de aceite:

- ✓ Toda previsão gerada possui um evento ou data clara de resolução em até 7 dias;
- ✓ A soma das probabilidades (SIM e NÃO) totaliza exatamente 100% em todas as saídas geradas;
- ✓ Nenhuma pergunta subjetiva ou aberta é gerada (apenas perguntas verificáveis de SIM/NÃO).

8.10 Extração de Entidades Críticas do Agronegócio (NER)

Sprint 3

Dupla B

Tarefas:

- Carregar o pipeline de NER com `pt_core_news_lg` do spaCy;
- Construir catálogo de entidades e termos estratégicos (Mapa, Conab, China, soja, milho, taxa Selic, geadas, embargo, Plano Safra);
- Aplicar peso multiplicador +1,5 no score dos clusters que contenham menções a essas entidades cruciais.

Critérios de aceite:

- ✓ Matérias com repercussão macroeconômica ou regulatória superam notícias institucionais ou corporativas no ranking;
- ✓ A extração das entidades roda em menos de 100ms por artigo analisado.

8.11 Balanceamento Editorial (Filtro Anti-Monotonia)

Sprint 3

Dupla B

Tarefas:

- Categorizar os clusters ranqueados em macro-temas (Mercado e Cotações, Clima e Safra, Políticas e Financiamento, Pecuária, Insumos e Tecnologia);
- Construir algoritmo de seleção gulosa (greedy selection) que percorre os clusters por score limitando o teto a no máximo 2 notícias por macro-tema;
- Fechar a lista final com exatamente os 5 clusters aprovados para a edição.

Critérios de aceite:

- ✓ A lista final contém rigorosamente 5 histórias;
- ✓ Nenhuma categoria temática ultrapassa o limite de 2 matérias na seleção final do dia.

8.12 Painel Web de Curadoria e Aprovação

Sprint 3

Dupla C

Tarefas:

- Desenvolver interface web ágil com Streamlit;
- Exibir os 5 blocos do dia contendo o texto, a barra de sentimento com justificativa e os cards do Polymarket (pergunta, odds e gatilho);
- Criar campos de edição para permitir correções pontuais no texto ou nos percentuais;
- Adicionar botão de ação principal: “Salvar Alterações e Aprovar Envio”.

Critérios de aceite:

- ✓ Edições realizadas nos campos de texto são salvas no banco imediatamente;
- ✓ O curador conclui a checagem e libera a edição final em menos de 5 minutos.

8.13 Monitor de Integridade e Alerta de Queda de Scraper

Sprint 3

Dupla A

Tarefas:

- Criar rotina de verificação disparada após cada ciclo de ingestão;
- Definir regra de alerta: se qualquer portal registrar 0 matérias novas nas últimas 24h, ativar notificação;
- Integrar disparo de webhook para Telegram ou Discord indicando o portal inativo.

Critérios de aceite:

- ✓ Mensagem de alerta recebida no canal da equipe com data, hora e nome do portal com falha;
- ✓ Zero falsos alertas emitidos durante o funcionamento regular dos 5 sites.

8.14 Componentes Visuais de E-mail (Termômetro & Odds Polymarket)

Sprint 4

Dupla C

- Tarefas:**
- Criar template HTML responsivo baseado no design minimalista da The News;
 - Componente Termômetro: construir barra horizontal de progresso em HTML/CSS inline dividida em três cores (verde = positivo, vermelho = negativo, cinza = neutro) com marcação percentual;
 - Componente Mercado Preditivo (Polymarket): desenvolver card visual com a pergunta preditiva e dois botões estilizados lado a lado exibindo SIM % e NÃO %, seguidos da data/gatilho de resolução;
 - Integrar a geração dos e-mails com a API do provedor de envio (Resend ou SendGrid).
- Critérios de aceite:**
- ✓ Renderização idêntica e sem quebras visuais no Gmail (Web, Android, iOS) e Apple Mail;
 - ✓ Ausência total de scripts JavaScript ou folhas CSS externas proibidas por clientes de e-mail.

8.15 Pipeline Diário Integrado de Execução Autônoma

Sprint 4

Duplas A + B

- Tarefas:**
- Criar o script orquestrador `pipeline_diario.py` que encadeia: fechamento das notícias → embeddings → clusterização → relevância (score) → seleção dos Top 5 → chamada das LLMs para texto, sentimento e previsões;
 - Agendar a execução do pipeline mestre para rodar pontualmente às 05h00 da manhã;
 - Salvar os dados completos no banco com status aguardando_aprovacao_curador.
- Critérios de aceite:**
- ✓ Execução ponta a ponta sem intervenção manual finalizada em menos de 8 minutos para 200 matérias;
 - ✓ Os 5 tópicos completos ficam disponíveis no painel de curadoria antes das 05h15 da manhã.

8.16 Teste de Carga e Validação Preditiva com Dados Históricos

Sprint 4

Duplas A + B + C

Corresponde diretamente à US-16 (validação de robustez em dias de crise de mercado).

- Tarefas:**
- Dupla A: injetar 500 matérias históricas de uma semana de forte oscilação de mercado no banco de dados;
 - Dupla B: rodar o pipeline de NLP validando o consumo de memória RAM durante a clusterização e verificar a coerência do termômetro de sentimento;
 - Dupla C: avaliar a aderência e coerência das perguntas estilo Polymarket geradas frente aos acontecimentos reais daquele período histórico;
 - Realizar disparo de teste da edição para a caixa postal de todos os membros da equipe.
- Critérios de aceite:**
- ✓ Zero falhas de estouro de memória (Out of Memory) durante o cálculo matricial;
 - ✓ Pelo menos 4 das 5 notícias selecionadas no teste histórico correspondem aos temas dominantes do período analisado;
 - ✓ Aprovação do envio teste por todas as duplas.

9. Stack Tecnológica

Camada	Ferramenta	Uso no produto
--------	------------	----------------

Coleta de dados	trafilatura / newspaper3k	Scraping estruturado dos 5 portais-fonte, com limpeza de HTML.
Agendamento	APScheduler / Celery	Execução periódica dos scrapers (3/3h) e do pipeline mestre (5h00).
Persistência	PostgreSQL (Docker/Cloud)	Armazenamento de artigos, clusters, scores e status editorial.
Embeddings semânticos	sentence-transformers (paraphrase-multilingual-MiniLM-L12-v2) + PyTorch	Vetorização de título+lead para comparação de similaridade entre notícias.
Clusterização	scikit-learn (DBSCAN, distância de cosseno)	Agrupamento de matérias que tratam do mesmo fato.
NER / entidades	spaCy (pt_core_news_lg)	Deteção de entidades críticas do agro para ponderação de score.
Classificação de sentimento	BERTimbau (neuralmind/bert-base-portuguese-cased) e/ou LLM via few-shot	Base de referência em português para o termômetro setorial (positivo/negativo/neutro).
Geração de texto e JSON estruturado	API de LLM + Pydantic + tenacity	Redação da notícia, termômetro e cenário preditivo, com validação de schema e retentativa.
Painel de curadoria	Streamlit	Interface de revisão e aprovação humana da edição diária.
Envio de e-mail	Resend / SendGrid + HTML/CSS inline	Disparo da newsletter com componentes visuais do termômetro e das odds.
Alertas operacionais	Webhook Telegram/Discord	Notificação em tempo real de falhas de coleta.

10. Plano de Sprints e Responsabilidades (Squad 3)

O squad está organizado em três duplas de trabalho, com responsabilidades técnicas fixas ao longo das quatro sprints:

Dupla	Frente técnica
Dupla A	Coleta, infraestrutura de dados e automação (scraping, banco, agendamento, monitoramento de integridade).
Dupla B	Núcleo de NLP analítico (embeddings, clusterização, score de relevância, NER, classificação de sentimento, balanceamento editorial).
Dupla C	Geração de conteúdo via LLM, previsão de cenários, painel de curadoria e camada de apresentação do e-mail.

Sprint	Fase	Entregas principais
Sprint 1	Explore	Coleta e normalização dos 5 portais (Dupla A); geração de embeddings (Dupla B); definição da persona editorial “The News Agro” (Dupla C).
Sprint 2	Build	Automação agendada da coleta (Dupla A); clusterização, score de relevância e termômetro de sentimento (Dupla B); geração estruturada via LLM com JSON validado (Dupla C).
Sprint 3	Refine	Monitor de integridade dos scrapers (Dupla A); NER de entidades críticas e balanceamento editorial (Dupla B); motor preditivo estilo Polymarket e painel de curadoria (Dupla C).
Sprint 4	Ship	Pipeline diário integrado às 05h00 (Duplas A+B); componentes visuais do e-mail (Dupla C); teste de carga e validação preditiva com dados históricos (todas as duplas).

Sprint Review 1: 04/09/2026, com apresentação de 10 minutos cobrindo conceito matemático, propósito, cenários de uso, problema resolvido e exemplos práticos do modelo de NLP, conforme roteiro obrigatório do Encontro 04.

11. Métricas de Sucesso e Critérios de Aceite Globais

Métrica	Meta
Cobertura de fontes	≥ 10 matérias reais extraídas de cada um dos 5 portais, sem duplicação de URL.
Precisão da deduplicação semântica	Similaridade de cosseno > 0,80 entre coberturas do mesmo fato; < 5% de agrupamentos incorretos.
Precisão do score de relevância	Tema coberto por 4+ portais sempre supera tema repetido por 1 único portal; cálculo em < 5s.
Acurácia do termômetro de sentimento	≥ 85% de concordância com avaliação humana especialista, em amostra de 30 notícias históricas.
Qualidade editorial	100% dos textos seguem a estrutura de 4 blocos; até 180 palavras por notícia.
Coerência preditiva	100% das previsões com gatilho de resolução em até 7 dias e soma de probabilidades = 100%.
Desempenho do pipeline	Execução ponta a ponta < 8 minutos para 200 matérias; edição pronta no painel antes das 05h15.
Tempo de curadoria humana	Aprovação da edição diária em < 5 minutos pelo curador.
Robustez sob carga	Zero falhas de memória (OOM) ao processar 500 matérias históricas de semana de alta volatilidade.
Confiabilidade de monitoramento	Zero falsos alertas de queda de portal durante operação regular.
Compatibilidade de e-mail	Renderização sem quebras em Gmail (Web/Android/iOS) e Apple Mail, sem JS ou CSS externo.

12. Riscos e Mitigações

Risco	Mitigação prevista
Mudança de estrutura HTML dos portais-fonte quebra o scraper.	Monitor de integridade com alerta automático (webhook) quando um portal para de retornar matérias novas.
Eps mal calibrado no DBSCAN gera clusters incorretos (mistura de assuntos distintos).	Calibração supervisionada do parâmetro eps (0,15–0,25) usando dados reais da Sprint 1 antes de produtivizar.
LLM retorna JSON malformatado e quebra o pipeline.	Validação obrigatória via schema Pydantic + modo JSON forçado na API + retentativa automática (tenacity, até 3x).
Edição enviesada para um único macro-tema (ex.: só soja).	Filtro anti-monotonia com teto de 2 notícias por macro-tema na seleção gulosa.
Sistema falha silenciosamente em dias de alta volatilidade de mercado.	Teste de carga e validação preditiva dedicado (Sprint 4) com 500 matérias históricas de semana de forte oscilação.
Quebra de renderização em clientes de e-mail (Gmail, Apple Mail).	Template HTML/CSS inline sem JavaScript nem folhas externas, testado nos principais clientes antes do disparo.

13. Fora de Escopo (Sprint 1–4)

- Aplicativo mobile nativo — a entrega é via e-mail responsivo;

- Personalização de conteúdo por perfil individual de assinante (segmentação de temas);
- Monetização, paywall ou modelo de assinatura paga;
- Expansão para portais além dos 5 definidos no board (TheAgriBiz, AgFeed, Agrolink, Canal Rural, Notícias Agrícolas);
- Suporte a idiomas além do português;
- Substituição total da curadoria humana por aprovação 100% automática do disparo.

Documento gerado a partir do board de planejamento do Squad 3 (Trello "Kanbam"), do site institucional da newsletter The News e do model card do BERTimbau, em conformidade com as diretrizes do Encontro 04 (28/08/26) da disciplina de Aprendizado de Máquina II.